



L'intelligence artificielle (IA) au service de la réputation en ligne

6 Dec 2021 - Tyson JOHN
Intelligence artificielle

Si les réseaux sociaux sont d'excellents outils de promotion, ils peuvent déclencher des crises aussi soudaines que brutales. Que ce soit le fait d'une 'fake news' ou d'un défaut de communication, les **Bad Buzz** peuvent profondément déstabiliser une entreprise, portant atteinte à sa crédibilité, ses résultats commerciaux, voire la relation de confiance qu'elle a avec ses propres salariés. Dans un monde ultra-connecté, la capacité de l'entreprise à mettre en place une veille active pour anticiper ce risque réputationnel devient capitale.

Dans cet article, *Marketing Intelligence Consulting* [1] se propose de vous exposer l'avantage décisif qu'apporte l'utilisation de l'intelligence artificielle dans la détection des Bad Buzz sur les réseaux sociaux. Nous vous présenterons trois approches permettant d'analyser les sentiments, notamment sur *Twitter*, afin d'être à l'écoute des commentaires concernant votre marque ou vos produits, et ainsi, repérer au plus vite les premiers signaux d'une crise potentielle.

Approche 1



Utilisation d'un outil « Clé en main » spécialisé dans la détection de sentiment

Approche 2



Utilisation d'une « boîte à outils » avec des modules à imbriquer pour former un modèle global

Approche 3



Utilisation de modèle(s) de réseaux de neurones profonds avec les plongements de mots



Pour cette étude, nous avons utilisé le jeu de données [Sentiment140](#) contenant 1,6 millions de tweets annotés – le texte brut et le sentiment qu'il exprime (0 pour négatif et 1 pour positif).

Un échantillon adapté a été utilisé pour chacune des approches utilisées.

Méthodologie et modélisation

Concernant les modèles, l'approche 1 utilise l'application Sentiment de Microsoft Azure Cognitive Services. L'approche 2 est basée sur un modèle de régression logistique utilisé dans le 'concepteur de modèle' de Microsoft Azure Machine Learning Studio. Enfin, l'approche 3 utilise un modèle de réseaux de neurones récurrents LSTM – adapté aux données séquentielles comme du texte ou des séries temporelles, et adossé à une infrastructure Tensorflow.

Deux étapes préalables sont essentielles lorsqu'on veut modéliser le langage à partir de sources textuelles : le prétraitement, qui normalise le texte, et la vectorisation, qui transforme le texte en nombre pour qu'il puisse être ingéré par la machine.

Dans notre prétraitement, nous avons supprimé les majuscules, les ponctuations, les caractères spéciaux et les nombres ; pour réduire la taille du vocabulaire, nous avons remplacé certains contenus spécifiques aux tweets (les mentions utilisateurs, les liens hypertextes et les mots-dièse par user, url et hashtag). Pour la vectorisation, l'approche 2 utilise l'extraction des caractéristiques n-grams (voir [wikipedia](#)) et l'approche 3 le plongement de mots (voir encadré).

Les métriques de performance utilisées sont l'AUC, qui mesure la capacité d'un modèle à classifier correctement, et l'Accuracy, qui mesure la proportion de prédictions correctes sur l'échantillon utilisé. Ci-dessous les résultats des 3 approches :

	Approche 1	Approche 2	Approche 3
AUC	75,99%	78,40%	79,02%
Accuracy	75,95%	70,60%	74,69%

Le choix d'une approche d'IA dépendra des besoins exprimés par les équipes en interne et des ressources disponibles

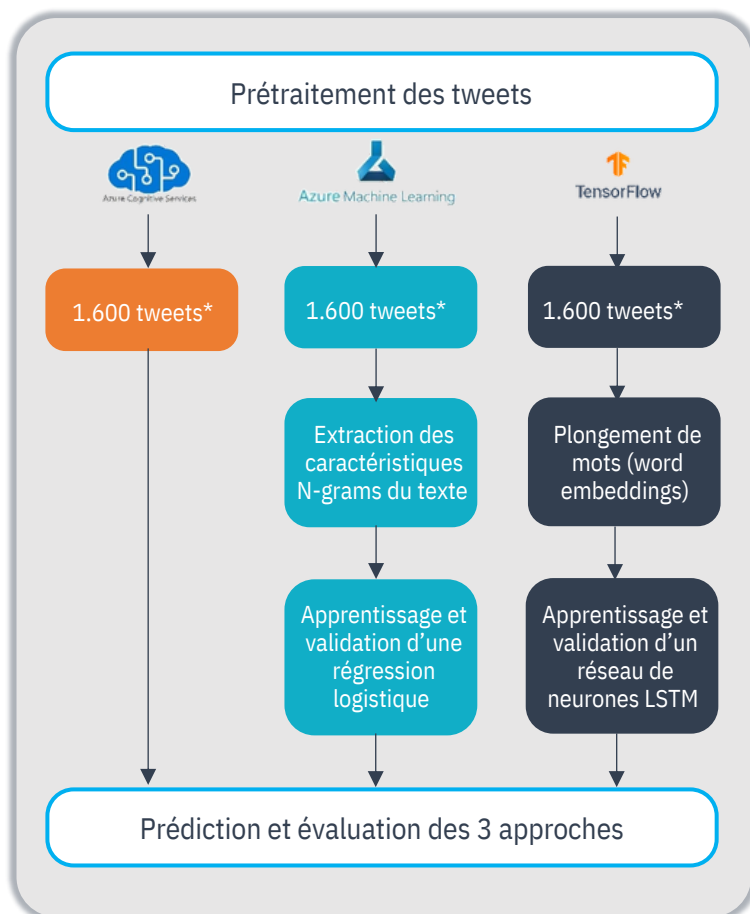
La 1ère approche conviendra aux utilisateurs désirant avoir à disposition un outil prêt à l'emploi : la solution la moins flexible pour un coût qui varie selon la volumétrie de données injectées, mais idéale pour commencer.

La 2e approche correspond à des profils ayant une connaissance de base en intelligence artificielle, mais qui veulent s'affranchir du code : une solution plus flexible impliquant un coût d'usage d'une machine virtuelle déportée.

La 3e approche requiert des profils avancés, ayant une expertise avérée en intelligence artificielle : la solution la plus flexible (modèle propriétaire) avec un coût en temps élevé pour trouver le modèle adapté et un coût Machine.

Afin que votre entreprise puisse se professionnaliser dans la gestion de sa réputation en ligne, le choix d'une approche dépendra des besoins exprimés par vos équipes en interne et des ressources disponibles, chaque méthode ayant ses avantages comme ses inconvénients. Marketing Intelligence Consulting[1] se propose de vous accompagner dans la mise en place d'un outil qui sera au plus proche de vos besoins.

[1] Marketing Intelligence Consulting est un nom de société fictif utilisé dans le cadre de cet article



Word Embeddings (ou plongement de mots)

Le plongement de mots est une structure de données textuelles où chaque mot est représenté par un vecteur de dimension fixe, les vecteurs étant peu distants pour des mots considérés comme sémantiquement similaires.

Sémantiquement, *chien* et *chat* sont plus proches que *chien* et *pomme* ou *chat* et *pomme*. En représentant les vecteurs des 3 mots sur 2 dimensions, on devrait voir la figure jointe.

